โครงงานเลขที่ วศ.คพ. **P019-2/2568**

เรื่อง

การแบ่งส่วนเนื้อเยื่อในช่องปากโดยตระหนักถึงการมีของรอยโรค

โดย

นายกรฤทธิ์ ปั้นนพศรี รหัส **650610744**

นางสาวชนันธร เชียงปวน รหัส **650610754**

โครงงานนี้

เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต

ภาควิชาวิศวกรรมคอมพิวเตอร์

คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่

ปีการศึกษา **2568**

PROJECT No. CPE P019-2/2568

Lesion-aware Oral Tissue Segmentation

Korarit Punnopsri 650610744
Chanuntorn Chiangpuan 650610754

A Project Submitted in Partial Fulfillment of Requirements
for the Degree of Bachelor of Engineering
Department of Computer Engineering
Faculty of Engineering
Chiang Mai University
2025

หัวข้อโครงงาน	: การแบ่งส่วนเนื้อเยื่อในช่องปากโดยตระหนักถึงการมีของรอยโรค
	: Lesion-aware Oral Tissue Segmentation
โดย	: นายกรฤทธิ์ ปั้นนพศรี รหัส 650610744
	นางสาวชนันธร เชียงปวน รหัส 650610754
ภาควิชา	: วิศวกรรมคอมพิวเตอร์
อาจารย์ที่ปรึกษา	: รศ.ดร. ปฏิเวธ วุฒิสารวัฒนา
ปริญญา	: วิศวกรรมศาสตรบัณฑิต
สาขา	: วิศวกรรมคอมพิวเตอร์
ปีการศึกษา	: 2568

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์ มหาวิทยาลัยเชียงใหม่ ได้อนุมัติให้โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต (สาขาวิศวกรรมคอมพิวเตอร์)

..... หัวหน้าภาควิชาวิศวกรรมคอมพิวเตอร์
(ผศ.ดร. นวดนย์ คุณเลิศกิจ)

คณะกรรมการสอบโครงงาน

..... ประธานกรรมการ
(รศ.ดร. ปฏิเวธ วุฒิสารวัฒนา)

..... กรรมการ
(ผศ.ดร. กานต์ ปทานุคม)

..... กรรมการ
(รศ.ดร. ศันสนีย์ เอื้อพันธ์วิริยะกุล)

หัวข้อโครงงาน	: การแบ่งส่วนเนื้อเยื่อในช่องปากโดยตระหนักถึงการมีของรอยโรค
	: Lesion-aware Oral Tissue Segmentation
โดย	: นายกรฤทธิ์ ปั้นนพศรี รหัส 650610744
	นางสาวชนันธร เชียงปวน รหัส 650610754
ภาควิชา	: วิศวกรรมคอมพิวเตอร์
อาจารย์ที่ปรึกษา	: รศ.ดร. ปฏิเวธ วุฒิสารวัฒนา
ปริญญา	: วิศวกรรมศาสตรบัณฑิต
สาขา	: วิศวกรรมคอมพิวเตอร์
ปีการศึกษา	: 2568

บทคัดย่อ

เขียนบทคัดย่อของโครงงานที่นี่

การเขียนรายงานเป็นส่วนหนึ่งของการทำโครงงานวิศวกรรมคอมพิวเตอร์ เพื่อทบทวนทฤษฎีที่เกี่ยวข้อง อธิบายขั้นตอนวิธีแก้ปัญหาเชิงวิศวกรรม และวิเคราะห์และสรุปผลการทดลองอุปกรณ์และระบบต่างๆ อย่างไรก็ดี การสร้างรูปเล่มรายงานให้ถูกรูปแบบนั้นเป็นขั้นตอนที่ยุ่งยาก แม้ว่าจะมีต้นแบบสำหรับใช้ในโปรแกรม Microsoft Word แล้วก็ตาม แต่นักศึกษาส่วนใหญ่ยังคงค้นพบว่าการใช้งานมีความซับซ้อน และเกิดความผิดพลาดในการจัดรูปแบบ กำหนดเลขหัวข้อ และสร้างสารบัญอยู่ ภาควิชาวิศวกรรมคอมพิวเตอร์จึงได้จัดทำต้นแบบรูปเล่มรายงานโดยใช้ระบบจัดเตรียมเอกสาร LaTeX เพื่อช่วยให้นักศึกษาเขียนรายงานได้อย่างสะดวกและรวดเร็วมากยิ่งขึ้น

Project Title	:	Lesion-aware Oral Tissue Segmentation
Name	:	Korarit Punnopsri 650610744
		Chanuntorn Chiangpuan 650610754
Department	:	Computer Engineering
Project Advisor	:	Assoc. Prof. Patiwet Wuttisarnwattana, Ph.D.
Degree	:	Bachelor of Engineering
Program	:	Computer Engineering
Academic Year	:	2025

ABSTRACT

The abstract would be placed here. It usually does not exceed 350 words long (not counting the heading), and must not take up more than one (1) page (even if fewer than 350 words long).

Make sure your abstract sits inside the `abstract` environment.

กิตติกรรมประกาศ

Your acknowledgments go here. Make sure it sits inside the `acknowledgment` environment.

นายกรฤทธิ์ ปั้นนพศรี
นางสาวชนันธร เชียงปวน
25 พฤษภาคม 2563

สารบัญ

บทคัดย่อ . . . . . ข
Abstract . . . . . ค
กิตติกรรมประกาศ . . . . . ง
สารบัญ . . . . . จ
สารบัญรูป . . . . . ช
สารบัญตาราง . . . . . ซ

1 บทนำ **1**
1.1 ที่มาของโครงงาน 1
1.2 วัตถุประสงค์ของโครงงาน 1
1.3 ขอบเขตของโครงงาน 1
1.3.1 ขอบเขตด้านฮาร์ดแวร์ 1
1.3.2 ขอบเขตด้านการศึกษา 2
1.4 ประโยชน์ที่ได้รับ 2
1.5 เทคโนโลยีและเครื่องมือที่ใช้ 2
1.5.1 เทคโนโลยีด้านฮาร์ดแวร์ 2
1.5.2 เทคโนโลยีด้านซอฟต์แวร์ 3
1.6 แผนการดำเนินงาน 3
1.7 บทบาทและความรับผิดชอบ 4
1.8 ผลกระทบด้านสังคม สุขภาพ ความปลอดภัย กฎหมาย และวัฒนธรรม 5

2 ทฤษฎีที่เกี่ยวข้อง **6**
2.1 การแบ่งส่วนภาพ (Image Segmentation) 6
2.2 Convolutional Neural Network (CNN) 7
2.3 แบบจำลองสำหรับการแบ่งส่วนภาพ (Segmentation Models) 7
2.3.1 U-Net 7
2.3.2 LinkNet 8
2.3.3 DeepLabV3+ 9
2.3.4 UPerNet 9
2.4 Encoder / Backbone 10
2.4.1 ResNet50 และ ResNet101 10
2.4.2 MobileNetV2 10
2.4.3 EfficientNet-B3 และ EfficientNet-B7 11
2.5 Loss Function 11
2.5.1 Dice Loss 11
2.5.2 Cross-Entropy Loss 11
2.5.3 การใช้งานร่วมกันของ Dice Loss และ Cross-Entropy Loss 12
2.6 การประมวลผลข้อมูลขั้นต้น (Preprocessing) 12
2.7 การประมวลผลผลลัพธ์ (Post-processing) 12
2.8 Connectivity (การเชื่อมต่อของพิกเซล) 13
2.9 Evaluation Metrics 14
2.9.1 Precision 14
2.9.2 Recall 14
2.9.3 F1-score 15
2.9.4 Intersection over Union (IoU) 15

2.9.5 Boundary F1 Score 15

3 โครงสร้างและขั้นตอนการทำงาน **16**
3.1 การจัดการข้อมูลและการเตรียมข้อมูล 16
3.2 การประมวลผลข้อมูลขั้นต้น (Preprocessing) 17
3.2.1 การวิเคราะห์การกระจายขนาดวัตถุ (Object Size Distribution Analysis) . . 17
3.2.2 การรวมวัตถุขนาดเล็ก (Context-aware Small Object Merging) 17
3.2.3 การรวมพื้นหลังภายในวัตถุ (Background Hole Merging) 18
3.2.4 การเติมเต็มช่องว่างภายในวัตถุ (Hole Filling) 18
3.3 การปรับปรุงผลลัพธ์ (Post-processing) 18
3.3.1 การลบวัตถุขนาดเล็กและการเติมเต็มช่องว่าง (Small Object Removal and Hole Filling) 18
3.3.2 การวิเคราะห์ความสัมพันธ์ระหว่างคลาส (Class Containment Analysis) . . . 18
3.3.3 การปรับปรุงผลลัพธ์ด้วยกฎเชิงตรรกะ (Rule-based Correction) 19

4 การทดลองและผลลัพธ์ **20**

5 บทสรุปและข้อเสนอแนะ **21**
5.1 สรุปผล 21
5.2 ปัญหาที่พบและแนวทางการแก้ไข 21
5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อ 21

บรรณานุกรม **22**

ก The first appendix **25**
ก.1 Appendix section 25

ข คู่มือการใช้งานระบบ **26**

ประวัติผู้เขียน **27**

สารบัญรูป

2.1 ตัวอย่างภาพแสดงประเภทของการแบ่งส่วนภาพ ได้แก่ Semantic Segmentation, Instance Segmentation และ Panoptic Segmentation [14] 6
2.2 โครงสร้างพื้นฐานของ Convolutional Neural Network (CNN) ที่ประกอบด้วย convolutional layer, activation function, pooling layer และ fully connected layer [5] 7
2.3 โครงสร้างของ U-Net ซึ่งประกอบด้วยส่วน encoder และ decoder ที่เชื่อมต่อกันด้วย skip connections [17] 8
2.4 โครงสร้างของ LinkNet ที่มีการเชื่อมต่อแบบ residual connections ระหว่าง encoder และ decoder [1] 8
2.5 โครงสร้างของ DeepLabV3+ ที่ใช้ atrous convolution และ ASPP เพื่อเพิ่มความสามารถในการจับบริบทของภาพ [2] 9
2.6 โครงสร้างของ UPerNet ที่ผสาน FPN และ PPM เพื่อรวมข้อมูลจากหลายระดับของ feature map [24] 10
2.7 ภาพแสดงความแตกต่างระหว่าง 4-connectivity และ 8-connectivity ในการพิจารณาการเชื่อมต่อของพิกเซล [15] 13

3.1 Poem 17

สารบัญตาราง

3.1 ตารางแสดงจำนวนภาพแบ่งตามมุมมองมาตรฐานและประเภทของรอยโรค 16

บทที่ 1
บทนำ

1.1 ที่มาของโครงงาน

ในปัจจุบัน เทคโนโลยีปัญญาประดิษฐ์โดยเฉพาะด้านการประมวลผลภาพทางการแพทย์ ได้เข้ามามีบทบาทสำคัญในการช่วยวิเคราะห์และวินิจฉัยโรคจากภาพถ่ายทางคลินิก หนึ่งในงานที่ได้รับความสนใจคือการตรวจจับและแบ่งส่วนรอยโรคในภาพช่องปาก ซึ่งสามารถช่วยแพทย์ในการคัดกรองและติดตามอาการของผู้ป่วยได้อย่างมีประสิทธิภาพ

อย่างไรก็ตาม นอกจากการตรวจจับรอยโรคแล้ว การระบุว่า “รอยโรคเกิดขึ้นบนอวัยวะใด” เช่น กระพุ้งแก้ม ลิ้น หรือเพดานปาก ถือเป็นข้อมูลที่มีความสำคัญต่อการประเมินความรุนแรงของโรคและการวางแผนการรักษา แต่ในทางปฏิบัติ ภาพที่มีรอยโรคมักส่งผลให้ลักษณะทางกายวิภาคของอวัยวะผิดเพี้ยนไป ทำให้แบบจำลองการแบ่งส่วนอวัยวะทำงานได้ยากและมีความคลาดเคลื่อนมากขึ้น โดยเฉพาะในกรณีของภาพที่ไม่เคยปรากฏในชุดข้อมูลฝึก

จากปัญหาดังกล่าว งานวิจัยนี้จึงมุ่งเน้นการศึกษาความสามารถของแบบจำลองในการแบ่งส่วนอวัยวะในภาพช่องปากที่มีรอยโรคร่วมอยู่ รวมถึงการวิเคราะห์ว่าการประยุกต์ใช้กระบวนการ preprocessing และ post-processing สามารถช่วยเพิ่มประสิทธิภาพของแบบจำลองได้หรือไม่ เพื่อให้เข้าใจข้อจำกัดและศักยภาพของระบบในสถานการณ์จริงมากยิ่งขึ้น

1.2 วัตถุประสงค์ของโครงงาน

1. เพื่อศึกษาความสามารถของแบบจำลองการแบ่งส่วนอวัยวะ เมื่อทำการฝึกแบบจำลองโดยใช้ภาพที่มีรอยโรคร่วมอยู่
2. เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองภายใต้กระบวนการประมวลผลที่แตกต่างกัน ได้แก่
    - แบบจำลองพื้นฐาน (baseline model)
    - แบบจำลองร่วมกับ preprocessing
    - แบบจำลองร่วมกับ preprocessing และ post-processing

1.3 ขอบเขตของโครงงาน

1.3.1 ขอบเขตด้านฮาร์ดแวร์

โครงงานนี้ดำเนินการบนเครื่องคอมพิวเตอร์สมรรถนะสูง (Deep Server) ซึ่งประกอบด้วย CPU รุ่น Intel Xeon Gold 5218 และ GPU รุ่น NVIDIA Quadro RTX 8000 ขนาด 48 GB จำนวน 2 การ์ด โดยใช้สำหรับการฝึกและทดสอบแบบจำลองการเรียนรู้เชิงลึก ทั้งนี้ ข้อจำกัดด้านทรัพยากร เช่น หน่วยความจำ GPU และเวลาในการใช้งาน อาจส่งผลต่อการกำหนดค่าพารามิเตอร์ของแบบจำลอง โครงงานนี้พัฒนาและทดสอบแบบจำลองโดยใช้ภาษา Python ร่วมกับไลบรารีด้านการประมวลผลภาพและการเรียนรู้ของเครื่อง เช่น PyTorch, OpenCV และ NumPy รวมถึงเครื่องมือสำหรับการจัดการและวิเคราะห์ข้อมูล โดยไม่ได้มีการพัฒนา framework ใหม่ขึ้นมา

1.3.2 ขอบเขตด้านการศึกษา

1. ศึกษาและประเมินแบบจำลองการแบ่งส่วนภาพ (image segmentation) สำหรับการระบุอวัยวะในภาพช่องปาก โดยใช้ข้อมูลภาพที่มีรอยโรคร่วมอยู่
2. ใช้แบบจำลองที่มีอยู่แล้ว (pre-existing model) โดยไม่เน้นการพัฒนาโครงสร้างโมเดลใหม่ แต่เน้นการประเมินประสิทธิภาพของโมเดลภายใต้เงื่อนไขที่แตกต่างกัน
3. ศึกษาผลของกระบวนการ preprocessing เช่น การปรับปรุงคุณภาพภาพ หรือการเตรียมข้อมูล ก่อนนำเข้าสู่แบบจำลอง
4. ศึกษาผลของกระบวนการ post-processing เช่น rule-based methods หรือการปรับปรุงผลลัพธ์ segmentation เพื่อเพิ่มความถูกต้องของผลลัพธ์
5. เปรียบเทียบประสิทธิภาพของระบบใน 3 รูปแบบ ได้แก่
   - แบบจำลองพื้นฐาน (baseline)
   - แบบจำลองร่วมกับ preprocessing
   - แบบจำลองร่วมกับ preprocessing และ post-processing
6. การประเมินผลจะพิจารณาจากตัวชี้วัดด้านความแม่นยำของการแบ่งส่วน และการวิเคราะห์ข้อผิดพลาดของโมเดล โดยเฉพาะในภาพที่หรือไม่เคยปรากฏในชุดข้อมูลฝึก

1.4 ประโยชน์ที่ได้รับ

1. ทำให้ทราบถึงความสามารถและข้อจำกัดของแบบจำลองในการแบ่งส่วนอวัยวะในภาพช่องปากที่มีรอยโรค ซึ่งใกล้เคียงกับสถานการณ์ใช้งานจริง
2. ช่วยให้เข้าใจผลกระทบของรอยโรคต่อความแม่นยำของการแบ่งส่วนอวัยวะ และลักษณะของข้อผิดพลาดที่เกิดขึ้น
3. แสดงให้เห็นว่าการประยุกต์ใช้ preprocessing และ post-processing สามารถช่วยปรับปรุงประสิทธิภาพของแบบจำลองได้ในระดับใด
4. เป็นแนวทางในการพัฒนาระบบวิเคราะห์ภาพทางการแพทย์ในอนาคต โดยเฉพาะในงานที่ต้องจัดการกับข้อมูลที่มีความซับซ้อนสูง
5. สามารถนำผลการศึกษาไปใช้เป็นข้อมูลอ้างอิงในการออกแบบหรือปรับปรุง pipeline สำหรับงาน segmentation ในบริบทอื่น ๆ ได้

1.5 เทคโนโลยีและเครื่องมือที่ใช้

1.5.1 เทคโนโลยีด้านฮาร์ดแวร์

- เครื่องคอมพิวเตอร์ส่วนบุคคล
- เครื่องคอมพิวเตอร์สมรรถนะสูง Deep Server จากภาควิชาวิศวกรรมคอมพิวเตอร์ มีหน่วยประมวลผลกลาง (CPU) รุ่น Intel(R) Xeon(R) Gold 5218 CPU @ 2.30GHz หน่วยประมวลผลกราฟฟิก (GPU) รุ่น NVIDIA Quadro RTX 8000 48Gb × 2 cards

1.5.2 เทคโนโลยีด้านซอฟต์แวร์

โครงงานนี้พัฒนาโดยใช้ภาษา Python และเครื่องมือที่เกี่ยวข้องกับการเรียนรู้เชิงลึกและการประมวลผลภาพ ดังนี้

1. เฟรมเวิร์กสำหรับ Deep Learning
   - PyTorch: ใช้สำหรับพัฒนา ฝึก และทดสอบแบบจำลองการแบ่งส่วนภาพ (image segmentation) โดยรองรับการทำงานบน GPU
   - segmentation_models_pytorch (SMP): ใช้เป็นไลบรารีสำหรับสร้างแบบจำลอง segmentation เช่น U-Net, MobileNet หรือ DeepLabV3+ ซึ่งช่วยลดความซับซ้อนในการพัฒนาโมเดล
2. ไลบรารีสำหรับการประมวลผลภาพ
   - OpenCV: ใช้สำหรับการประมวลผลภาพ เช่น การปรับขนาดภาพ การปรับปรุงคุณภาพภาพ และการเตรียมข้อมูลก่อนนำเข้าสู่แบบจำลอง
   - SciPy: ใช้สำหรับการวิเคราะห์โครงสร้างของภาพ เช่น การตรวจสอบ connectivity ของพิกเซล และการปรับปรุงผลลัพธ์ในขั้นตอน post-processing
3. ไลบรารีสำหรับการจัดการข้อมูล
   - Pandas: ใช้สำหรับจัดเก็บและวิเคราะห์ผลลัพธ์ เช่น การบันทึกค่า metric และผลการทดลอง
   - NumPy: ใช้สำหรับการคำนวณทางคณิตศาสตร์และการจัดการอาเรย์ของข้อมูล
   - collections (Counter): ใช้สำหรับการนับจำนวนตัวอย่างในแต่ละคลาส นับจำนวนพิกเซลในแต่ละคลาส และการวิเคราะห์ความสมดุลของข้อมูล
4. เครื่องมือสนับสนุนการพัฒนา
   - os และ pathlib: ใช้สำหรับจัดการไฟล์และโฟลเดอร์ของชุดข้อมูล
   - time: ใช้สำหรับวัดระยะเวลาในการประมวลผลในแต่ละขั้นตอน
   - sys: ใช้สำหรับควบคุมการทำงานของโปรแกรมและการรับพารามิเตอร์จากระบบ
   - Jupyter Notebook: ใช้สำหรับการทดลองและวิเคราะห์ข้อมูลแบบ interactive
   - Git: ใช้สำหรับการควบคุมเวอร์ชันของโค้ดและการทำงานร่วมกันในทีม

1.6 แผนการดำเนินงาน

ขั้นตอนการดำเนินงาน	พ.ย. 2567	ธ.ค. 2567	ม.ค. 2568	ก.พ. 2568	มี.ค. 2568
ศึกษาค้นคว้าทฤษฎีที่เกี่ยวข้อง					
เก็บรวบรวมข้อมูลและจัดเตรียมข้อมูลสำหรับการฝึกสอน					

ขั้นตอนการดำเนินงาน	พ.ย. 2568	ธ.ค. 2568	ม.ค. 2569	ก.พ. 2569	มี.ค. 2569
เลือกโมเดลฝึกสอน					
เก็บรวบรวมข้อมูลและจัดเตรียมข้อมูลสำหรับการฝึกสอน					
ฝึกสอน ทดสอบ และปรับปรุงอัลกอริทึม					
บันทึกผล วิเคราะห์ และสรุปผล					
จัดทำรายงาน โปสเตอร์ และนำเสนอ					

1.7 บทบาทและความรับผิดชอบ

1. นายกรฤทธิ์ ปั้นนพศรี
   - จัดเตรียมและตรวจสอบความถูกต้องของข้อมูลสำหรับการทำ Data Labeling
   - ออกแบบและดำเนินการฝึกสอนแบบจำลอง (Model Training) โดยใช้ข้อมูลที่เตรียมไว้
   - ดำเนินการทดสอบแบบจำลอง (Model Testing) ในสภาวะต่าง ๆ เพื่อประเมินประสิทธิภาพ
   - วิเคราะห์ผลลัพธ์ของแบบจำลองในเชิงปริมาณและเชิงคุณภาพ เช่น ความแม่นยำ และลักษณะของข้อผิดพลาด
2. นางสาวชนันธร เชียงปวน
   - จัดเตรียมและตรวจสอบความถูกต้องของข้อมูลสำหรับการทำ Data Labeling
   - ออกแบบและพัฒนากระบวนการ preprocessing เพื่อปรับปรุงคุณภาพของข้อมูลภาพก่อนนำเข้าสู่แบบจำลอง
   - ออกแบบและพัฒนากระบวนการ post-processing โดยใช้เทคนิคเชิงกฎ (rule-based) และการวิเคราะห์ connectivity ของพิกเซล เพื่อปรับปรุงผลลัพธ์ของการแบ่งส่วนภาพ
   - ดำเนินการทดสอบแบบจำลองภายใต้ pipeline ที่ประกอบด้วย preprocessing และ post-processing
   - วิเคราะห์ผลกระทบของ preprocessing และ post-processing ต่อประสิทธิภาพของแบบจำลอง และเปรียบเทียบผลลัพธ์กับแบบจำลองพื้นฐาน

1.8 ผลกระทบด้านสังคม สุขภาพ ความปลอดภัย กฎหมาย และวัฒนธรรม

1. ผลกระทบด้านสังคม

   โครงงานนี้มีศักยภาพในการสนับสนุนระบบสาธารณสุข โดยเฉพาะในด้านการคัดกรองและวิเคราะห์ภาพช่องปาก ซึ่งสามารถช่วยลดภาระของบุคลากรทางการแพทย์ และเพิ่มโอกาสในการเข้าถึงการตรวจวินิจฉัยเบื้องต้นของประชาชน โดยเฉพาะในพื้นที่ที่ขาดแคลนผู้เชี่ยวชาญ
   อย่างไรก็ตาม การนำระบบปัญญาประดิษฐ์มาใช้งานอาจก่อให้เกิดความกังวลในสังคมเกี่ยวกับความน่าเชื่อถือของระบบ และการทดแทนบทบาทของมนุษย์ ดังนั้น การใช้งานควรอยู่ภายใต้การกำกับดูแลของผู้เชี่ยวชาญ

2. ผลกระทบด้านสุขภาพ

   การพัฒนาเทคโนโลยีนี้สามารถช่วยสนับสนุนการตรวจจับและวิเคราะห์รอยโรคในช่องปากได้อย่างรวดเร็ว ซึ่งอาจนำไปสู่การวินิจฉัยและการรักษาที่ทันท่วงที ลดความเสี่ยงของการลุกลามของโรค
   อย่างไรก็ตาม หากแบบจำลองมีความคลาดเคลื่อน โดยเฉพาะในภาพที่มีลักษณะซับซ้อน อาจนำไปสู่การวินิจฉัยที่ผิดพลาด ดังนั้น ระบบควรถูกใช้เป็นเครื่องมือช่วยตัดสินใจ (decision support) ไม่ใช่การทดแทนการวินิจฉัยโดยแพทย์

3. ผลกระทบด้านความปลอดภัย

   การใช้ระบบปัญญาประดิษฐ์ในการวิเคราะห์ภาพทางการแพทย์จำเป็นต้องคำนึงถึงความปลอดภัยของข้อมูล โดยเฉพาะข้อมูลภาพของผู้ป่วย ซึ่งอาจมีความละเอียดอ่อนและต้องได้รับการปกป้องจากการเข้าถึงโดยไม่ได้รับอนุญาต
   นอกจากนี้ ความปลอดภัยในการใช้งานระบบยังรวมถึงความน่าเชื่อถือของผลลัพธ์ หากระบบให้ผลลัพธ์ที่ไม่ถูกต้อง อาจส่งผลกระทบต่อการตัดสินใจทางการแพทย์ได้

4. ผลกระทบด้านกฎหมาย

   ข้อมูลภาพทางการแพทย์ถือเป็นข้อมูลส่วนบุคคลที่มีความอ่อนไหว การนำมาใช้ในโครงงานจำเป็นต้องปฏิบัติตาม พระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล (PDPA) โดยต้องมีการขอความยินยอมจากเจ้าของข้อมูล และดำเนินการปกป้องข้อมูลอย่างเหมาะสม เช่น การไม่เปิดเผยตัวตนของผู้ป่วยและการจำกัดการเข้าถึงข้อมูล
   อีกทั้งหากมีการนำระบบไปใช้งานจริง ควรพิจารณาความรับผิดชอบทางกฎหมายในกรณีที่ผลลัพธ์ของระบบเกิดความคลาดเคลื่อนและส่งผลต่อการตัดสินใจทางการแพทย์

5. ผลกระทบด้านวัฒนธรรม

   การนำเทคโนโลยีปัญญาประดิษฐ์มาใช้ในงานด้านการแพทย์จำเป็นต้องคำนึงถึงความเชื่อและทัศนคติของผู้ใช้งาน โดยผู้ป่วยบางกลุ่มอาจยังไม่มั่นใจหรือไม่คุ้นเคยกับการใช้ระบบอัตโนมัติในการช่วยวินิจฉัยโรค ดังนั้น การนำเสนอผลลัพธ์ควรมีความชัดเจน เข้าใจง่าย และอยู่ภายใต้การดูแลของบุคลากรทางการแพทย์ เพื่อสร้างความเชื่อมั่นและการยอมรับในการใช้งานระบบมากยิ่งขึ้น

บทที่ 2
ทฤษฎีที่เกี่ยวข้อง

2.1 การแบ่งส่วนภาพ (Image Segmentation)

การแบ่งส่วนภาพ (Image Segmentation) เป็นกระบวนการสำคัญในงานประมวลผลภาพดิจิทัล โดยมีวัตถุประสงค์เพื่อแยกภาพออกเป็นส่วนย่อย ๆ หรือบริเวณ (regions) ที่มีความหมาย เพื่อให้ง่ายต่อการวิเคราะห์ในขั้นตอนถัดไป โดยทั่วไป การแบ่งส่วนภาพจะทำการจัดกลุ่มพิกเซลที่มีลักษณะคล้ายคลึงกัน เช่น สี ความเข้ม หรือพื้นผิว ให้อยู่ในกลุ่มเดียวกัน

การแบ่งส่วนภาพสามารถแบ่งออกได้เป็นหลายประเภท โดยประเภทที่นิยมในงานด้านปัญญาประดิษฐ์ ได้แก่ การแบ่งส่วนภาพเชิงความหมาย (Semantic Segmentation) ซึ่งเป็นการจำแนกประเภทให้กับพิกเซลในภาพว่าเป็นประเภทใด เช่น การระบุว่าแต่ละพิกเซลเป็นส่วนของอวัยวะใดในช่องปาก การแบ่งส่วนภาพเชิงวัตถุ (Instance Segmentation) คือ การแบ่งส่วนวเฉพาะวัตถุที่สนใจที่อาจปรากฏหลายวัตถุในภาพเดียวกัน เช่น ในภาพเดียวกันมีคนอยู่หลายคน การแบ่งส่วนแบบ Instance จะแยกคนแต่ละคนออกจากกัน และการแบ่งส่วนภาพแบบ Panoptic เป็นการแบ่งส่วนแบบรวม Semantic และ Instance เข้าด้วยกัน โดยมีเป้าหมายเพื่อระบุประเภทของพิกเซลทุกพิกเซลในภาพ ซึ่งกำหนดให้พิกเซลที่อยู่ในกลุ่ม ”Stuff” (พื้นหลังที่นับจำนวนไม่ได้ เช่น ถนน, ท้องฟ้า) ถูกจำแนกตามประเภทของข้อมูล และพิกเซลที่อยู่ในกลุ่ม ”Things” (วัตถุที่นับจำนวนได้ เช่น คน, รถยนต์) ถูกจำแนกทั้งประเภทและแยกแยะวัตถุออกจากกันอย่างชัดเจน [14]

ในบริบทของงานทางการแพทย์ การแบ่งส่วนภาพมีบทบาทสำคัญในการระบุขอบเขตของอวัยวะหรือรอยโรค ซึ่งช่วยให้สามารถประเมินลักษณะ ขนาด และตำแหน่งของความผิดปกติได้อย่างแม่นยำมากขึ้น [23] อย่างไรก็ตาม ภาพทางการแพทย์มักมีความซับซ้อนและแตกต่างกันในแต่ละบุคคล รวมถึงอาจมีสัญญาณรบกวน (noise) ซึ่งส่งผลต่อความยากในการแบ่งส่วนภาพ

ในอดีต อัลกอริทึมแบบดั้งเดิม เช่น Otsu thresholding, Watershed transform และ Active contour ถูกนำมาใช้อย่างแพร่หลายในงานแบ่งส่วนภาพทางการแพทย์ อย่างไรก็ตาม ในช่วงไม่กี่ปีที่ผ่านมา การเรียนรู้เชิงลึก (Deep Learning) ได้เข้ามามีบทบาทสำคัญ เนื่องจากสามารถให้ผลลัพธ์ที่มีความแม่นยำสูงกว่าในหลายงานวิจัย [14]

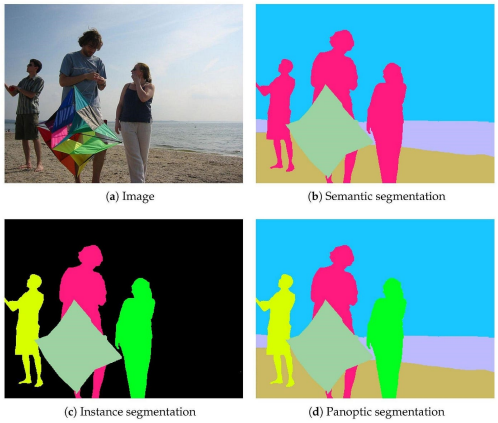

รูปที่ 2.1: ตัวอย่างภาพแสดงประเภทของการแบ่งส่วนภาพ ได้แก่ Semantic Segmentation, Instance Segmentation และ Panoptic Segmentation [14]

2.2 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) เป็นหนึ่งในสถาปัตยกรรมหลักของโครงข่ายประสาทเทียมในการเรียนรู้เชิงลึก (Deep Learning) ที่ถูกออกแบบมาเพื่อประมวลผลข้อมูลที่มีโครงสร้างเชิงพื้นที่ เช่น ภาพและวิดีโอ โดยมีจุดเด่นในการเรียนรู้คุณลักษณะ (features) จากข้อมูลได้โดยอัตโนมัติผ่านกระบวนการ convolution ซึ่งใช้ตัวกรอง (filters หรือ kernels) ในการตรวจจับลักษณะสำคัญของภาพ เช่น ขอบ (edges), มุม (corners) และรูปแบบเชิงซับซ้อนในระดับที่ลึกขึ้น [8, 10]

โครงสร้างพื้นฐานของ CNN ประกอบด้วยหลายชั้น (layers) ได้แก่ convolutional layer, activation function (เช่น ReLU), pooling layer และ fully connected layer โดย convolutional layer ทำหน้าที่สกัดคุณลักษณะจากภาพอินพุต (Input) ในขณะที่ pooling layer ช่วยลดขนาดของข้อมูล (downsampling) เพื่อลดความซับซ้อนและป้องกัน overfitting ส่วน activation function ช่วยเพิ่มความไม่เป็นเชิงเส้นให้กับโมเดล ทำให้สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนได้ [5] นอกจากนี้ CNN ยังมีคุณสมบัติสำคัญ เช่น local connectivity และ weight sharing ซึ่งช่วยลดจำนวนพารามิเตอร์ของโมเดลเมื่อเทียบกับโครงข่ายแบบ fully connected และทำให้สามารถเรียนรู้ได้อย่างมีประสิทธิภาพมากขึ้นในงานที่เกี่ยวข้องกับภาพ [10]

ในงานด้านการแบ่งส่วนภาพ CNN มักถูกนำมาใช้ในรูปแบบของ fully convolutional network (FCN) ซึ่งแทนที่ fully connected layer ด้วย convolutional layer ทั้งหมด เพื่อให้สามารถสร้างผลลัพธ์ในระดับพิกเซล (pixel-wise prediction) ได้ [12] โดยโครงสร้างแบบ encoder-decoder เช่น U-Net และ DeepLabV3+ เป็นการต่อยอดจากแนวคิดของ CNN เพื่อรักษาข้อมูลเชิงตำแหน่ง (spatial information) และเพิ่มความแม่นยำในการแบ่งส่วนภาพ [2, 17]

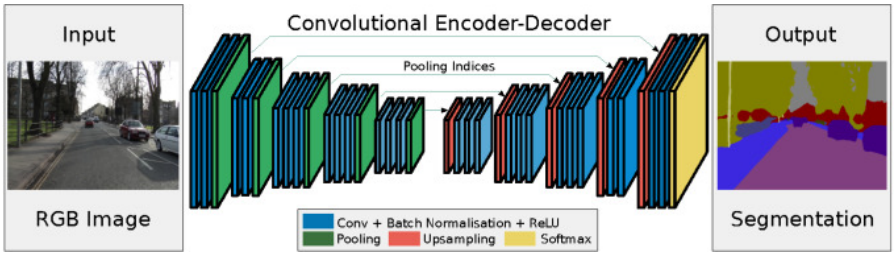

รูปที่ 2.2: โครงสร้างพื้นฐานของ Convolutional Neural Network (CNN) ที่ประกอบด้วย convolutional layer, activation function, pooling layer และ fully connected layer [5]

2.3 แบบจำลองสำหรับการแบ่งส่วนภาพ (Segmentation Models)

2.3.1 U-Net

U-Net เป็นแบบจำลองการแบ่งส่วนภาพที่ถูกออกแบบมาสำหรับงานทางการแพทย์โดยเฉพาะ โดยมีโครงสร้างแบบ encoder-decoder ที่มีลักษณะสมมาตร (symmetric architecture) ซึ่งประกอบด้วยส่วน encoder สำหรับลดขนาดของภาพและสกัดคุณลักษณะ และส่วน decoder สำหรับเพิ่มความละเอียดของภาพและสร้าง segmentation mask [17]

จุดเด่นสำคัญของ U-Net คือการใช้ skip connections ซึ่งเชื่อมต่อ feature map จาก encoder ไปยัง decoder ในระดับที่สอดคล้องกัน ช่วยให้โมเดลสามารถรักษาข้อมูลเชิงตำแหน่ง (spatial information)

และรายละเอียดของขอบวัตถุได้ดีขึ้น ส่งผลให้มีประสิทธิภาพสูงในการแบ่งส่วนภาพที่ต้องการความละเอียด เช่น ภาพทางการแพทย์ นอกจากนี้ U-Net ยังสามารถฝึกด้วยข้อมูลจำนวนน้อยได้ดีเมื่อเทียบกับโมเดลอื่น เนื่องจากมีการใช้ data augmentation และโครงสร้างที่เหมาะสมกับลักษณะของภาพทางการแพทย์

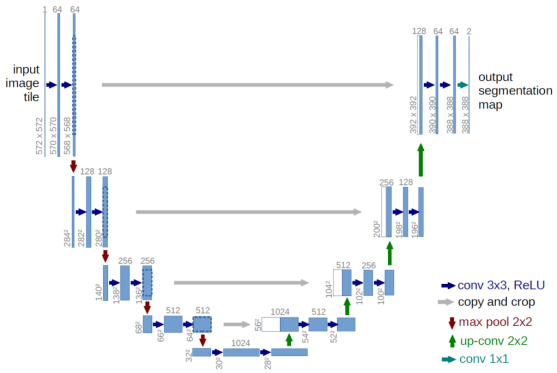

รูปที่ 2.3: โครงสร้างของ U-Net ซึ่งประกอบด้วยส่วน encoder และ decoder ที่เชื่อมต่อกันด้วย skip connections [17]

2.3.2 LinkNet

LinkNet เป็นแบบจำลอง segmentation ที่พัฒนาขึ้นโดยเน้นประสิทธิภาพในการประมวลผลและความเร็ว โดยมีโครงสร้างแบบ encoder-decoder เช่นเดียวกับ U-Net แต่มีการออกแบบให้ lightweight มากขึ้น [1] ใน LinkNet จะมีการเชื่อมต่อระหว่าง encoder และ decoder ผ่าน residual connections ซึ่งช่วยให้ข้อมูลสามารถไหลผ่านเครือข่ายได้อย่างมีประสิทธิภาพ และลดปัญหา gradient vanishing นอกจากนี้ LinkNet ยังมีจำนวนพารามิเตอร์น้อย ทำให้เหมาะสำหรับการใช้งานที่ต้องการความเร็วสูงหรือมีข้อจำกัดด้านทรัพยากร โมเดลนี้มักใช้ร่วมกับ encoder ที่มีประสิทธิภาพ เช่น ResNet หรือ MobileNet เพื่อเพิ่มความสามารถในการสกัดคุณลักษณะจากภาพ (Feature Extraction) และยังคงรักษาความเร็วในการประมวลผลที่ดี

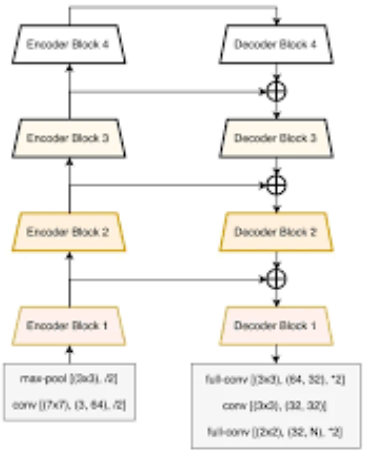

รูปที่ 2.4: โครงสร้างของ LinkNet ที่มีการเชื่อมต่อแบบ residual connections ระหว่าง encoder และ decoder [1]

2.3.3 DeepLabV3+

DeepLabV3+ เป็นแบบจำลอง segmentation ที่พัฒนาขึ้นเพื่อเพิ่มความสามารถในการจับบริบทของภาพ (context) และรายละเอียดของขอบวัตถุ โดยใช้เทคนิค atrous convolution (หรือ dilated convolution) ซึ่งช่วยเพิ่ม receptive field โดยไม่เพิ่มจำนวนพารามิเตอร์ [2] โครงสร้างของ DeepLabV3+ ประกอบด้วยส่วน encoder ที่ใช้ atrous spatial pyramid pooling (ASPP) เพื่อดึงข้อมูลในหลายสเกล และส่วน decoder ที่ช่วยปรับปรุงความละเอียดของขอบวัตถุให้คมชัดมากขึ้น

จุดเด่นของโมเดลนี้ คือ สามารถจัดการกับวัตถุที่มีขนาดแตกต่างกันในภาพเดียว และรักษารายละเอียดของ segmentation ได้ดี ทำให้ได้รับความนิยมในงาน segmentation ที่ต้องการความแม่นยำสูง

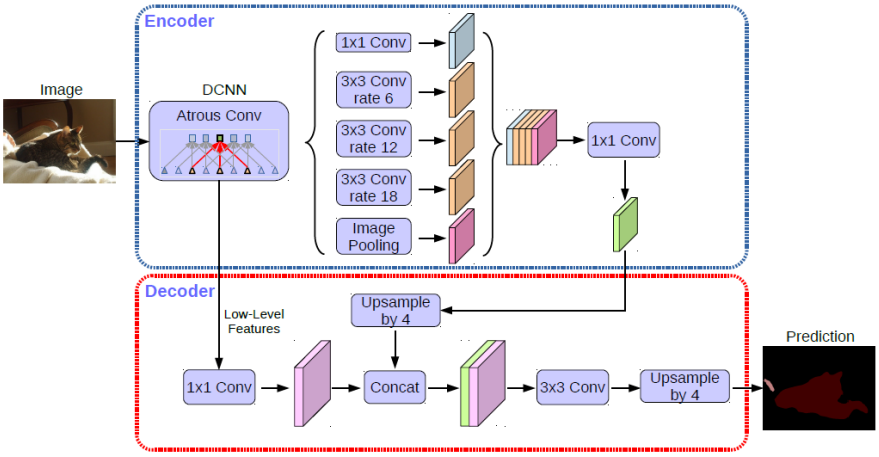

รูปที่ 2.5: โครงสร้างของ DeepLabV3+ ที่ใช้ atrous convolution และ ASPP เพื่อเพิ่มความสามารถในการจับบริบทของภาพ [2]

2.3.4 UPerNet

UPerNet (Unified Perceptual Parsing Network) เป็นแบบจำลอง segmentation ที่ออกแบบมาเพื่อรวมข้อมูลจากหลายระดับของ feature (multi-scale features) โดยใช้โครงสร้างที่ผสาน Feature Pyramid Network (FPN) และ Pyramid Pooling Module (PPM) เข้าด้วยกัน [24]

โดยที่ UPerNet มีการใช้ FPN เพื่อรวมข้อมูลจากหลายระดับของ feature map ซึ่งช่วยให้โมเดลสามารถจับบริบทของภาพได้ดีขึ้น ในขณะที่ PPM ช่วยให้โมเดลสามารถรวมข้อมูลจากหลายสเกลได้อย่างมีประสิทธิภาพ ทำให้สามารถจัดการกับวัตถุที่มีขนาดแตกต่างกันในภาพเดียวกันได้ดีขึ้น

UPerNet สามารถรวมข้อมูลทั้งในระดับ global context และ local detail ได้อย่างมีประสิทธิภาพ ทำให้สามารถจัดการกับภาพที่มีความซับซ้อนและมีวัตถุหลายขนาดได้ดี นอกจากนี้ยังสามารถนำไปประยุกต์ใช้กับงาน segmentation ที่ต้องการความละเอียดสูงและความเข้าใจเชิงบริบทของภาพ

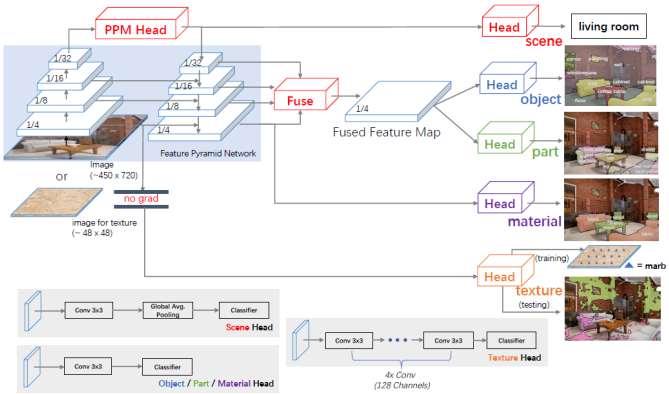

รูปที่ 2.6: โครงสร้างของ UPerNet ที่ผสาน FPN และ PPM เพื่อรวมข้อมูลจากหลายระดับของ feature map [24]

2.4 Encoder / Backbone

Encoder หรือ Backbone เป็นส่วนสำคัญของแบบจำลองการแบ่งส่วนภาพ ทำหน้าที่สกัดคุณลักษณะ (feature extraction) จากภาพอินพุต (Input) โดยทั่วไปจะใช้โครงข่ายที่ผ่านการฝึกสอนมาก่อน (pretrained models) บนชุดข้อมูลขนาดใหญ่ เช่น ImageNet เพื่อช่วยให้โมเดลสามารถเรียนรู้ลักษณะสำคัญของภาพได้อย่างมีประสิทธิภาพมากขึ้น [7, 18, 22]

2.4.1 ResNet50 และ ResNet101

ResNet (Residual Network) เป็นโครงข่ายประสาทเทียมที่พัฒนาเพื่อแก้ปัญหา vanishing gradient ในเครือข่ายที่มีความลึกมาก โดยใช้แนวคิด residual learning ซึ่งมีการเพิ่ม shortcut connection หรือ skip connection ระหว่างชั้น เพื่อให้โมเดลสามารถเรียนรู้ส่วนที่เหลือ (residual) ของข้อมูลแทนที่จะเรียนรู้ mapping ทั้งหมด [7]

ResNet50 และ ResNet101 แตกต่างกันที่จำนวนชั้น โดย ResNet50 มีประมาณ 50 ชั้น และ ResNet101 มีประมาณ 101 ชั้น ซึ่งทำให้ ResNet101 สามารถเรียนรู้คุณลักษณะที่ซับซ้อนมากขึ้น แต่ต้องใช้ทรัพยากรในการประมวลผลสูงกว่า จุดเด่นของ ResNet อยู่ที่ความสามารถในการเรียนรู้ feature เชิงลึกได้ดี และมีความเสถียรในการฝึก ทำให้ถูกนำมาใช้เป็น backbone ในงาน segmentation อย่างแพร่หลาย เช่น DeepLabV3+ และ UPerNet

2.4.2 MobileNetV2

MobileNetV2 เป็นโครงข่ายที่ออกแบบมาเพื่อให้มีขนาดเล็กและมีประสิทธิภาพสูง เหมาะสำหรับอุปกรณ์ที่มีข้อจำกัดด้านทรัพยากร โดยใช้แนวคิด inverted residual structure และ linear bottleneck ซึ่งช่วยลดจำนวนพารามิเตอร์และการคำนวณลงอย่างมาก [18]

โครงสร้าง inverted residual จะเริ่มจากการขยายมิติของ feature (expansion) จากนั้นทำ depthwise convolution และลดมิติกลับ (projection) ทำให้สามารถรักษาข้อมูลสำคัญได้ในขณะที่ลดความซับซ้อนของโมเดล MobileNetV2 จึงเหมาะสำหรับงานที่ต้องการความเร็ว เช่น real-time processing หรือระบบที่มีข้อจำกัดด้านหน่วยความจำ

2.4.3 EfficientNet-B3 และ EfficientNet-B7

EfficientNet เป็นโครงข่ายที่พัฒนาขึ้นเพื่อเพิ่มประสิทธิภาพของโมเดลโดยใช้แนวคิด compound scaling ซึ่งปรับขนาดของโมเดลในสามมิติ ได้แก่ ความลึก (depth), ความกว้าง (width) และความละเอียดของภาพ (resolution) อย่างสมดุล [22] EfficientNet-B3 และ EfficientNet-B7 เป็นเวอร์ชันที่มีขนาดแตกต่างกัน โดย:

- EfficientNet-B3 มีขนาดกลาง ให้สมดุลระหว่างความแม่นยำและความเร็ว
- EfficientNet-B7 มีขนาดใหญ่ ให้ความแม่นยำสูง แต่ใช้ทรัพยากรสูงมาก

EfficientNet เด่นด้านการใช้พารามิเตอร์อย่างมีประสิทธิภาพ ทำให้สามารถให้ผลลัพธ์ที่ดีในขณะที่ใช้ทรัพยากรน้อยกว่าโมเดลแบบดั้งเดิม

2.5 Loss Function

ในการฝึกแบบจำลองการแบ่งส่วนภาพ (image segmentation) ฟังก์ชันการสูญเสีย (loss function) มีบทบาทสำคัญในการวัดความแตกต่างระหว่างผลลัพธ์ที่แบบจำลองทำนาย (prediction) และข้อมูลจริง (ground truth) เพื่อปรับปรุงพารามิเตอร์ของโมเดลให้มีความแม่นยำมากขึ้น โดยในงานนี้เลือกใช้ Dice Loss และ Cross-Entropy Loss ซึ่งเป็นฟังก์ชันที่นิยมใช้ในงาน segmentation ทางการแพทย์ [13, 21]

2.5.1 Dice Loss

Dice Loss เป็นฟังก์ชันที่พัฒนามาจาก Dice Coefficient ซึ่งใช้วัดความสอดคล้องระหว่าง prediction และ ground truth โดยมีค่าอยู่ระหว่าง 0 ถึง 1 ซึ่งค่าที่สูงแสดงถึงความสอดคล้องที่ดี โดยสามารถนิยาม Dice Coefficient ได้ดังนี้

$$\text{Dice} = 1 - \frac{2\sum_{i=1}^{N} p_i g_i + \epsilon}{\sum_{i=1}^{N} p_i + \sum_{i=1}^{N} g_i + \epsilon} \tag{2.1}$$

โดยที่ p_i คือค่าที่โมเดลทำนายสำหรับพิกเซลที่ i, g_i คือค่าจริงของพิกเซลที่ i, และ ϵ เป็นค่าคงที่เล็ก ๆ เพื่อป้องกันการหารด้วยศูนย์

Dice Loss มีจุดเด่นด้านความสามารถในการจัดการกับปัญหา class imbalance ซึ่งมักพบในงาน segmentation ทางการแพทย์ เช่น กรณีที่พื้นที่ของรอยโรคมีขนาดเล็กเมื่อเทียบกับพื้นหลัง [13] นอกจากนี้ยังช่วยให้โมเดลเรียนรู้ขอบเขตของวัตถุได้ดีขึ้น ทว่า Dice Loss อาจมีความไม่เสถียรในช่วงเริ่มต้นของการฝึก เนื่องจากค่าของตัวหารอาจมีค่าน้อยมากในบางกรณี

2.5.2 Cross-Entropy Loss

Cross-Entropy Loss เป็นฟังก์ชันที่นิยมใช้ในงาน classification และสามารถนำมาประยุกต์ใช้ในงาน segmentation ได้ โดยทำการคำนวณความแตกต่างระหว่าง probability distribution ของ prediction และ ground truth โดยสำหรับกรณี binary segmentation สามารถนิยามได้ดังนี้

$$\mathscr{L}_{MCE} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} g_{ic}\log(p_{ic}) \tag{2.2}$$

โดยที่ N คือจำนวนพิกเซลทั้งหมด, C คือจำนวนคลาส, g_{ic} คือค่าจริงของพิกเซลที่ i สำหรับคลาส c, และ p_{ic} คือค่าที่โมเดลทำนายสำหรับพิกเซลที่ i สำหรับคลาส c

ข้อดีของ Cross-Entropy Loss คือความเสถียรในการฝึก และความสามารถในการทำให้โมเดลเรียนรู้การจำแนกพิกเซลได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม ฟังก์ชันนี้อาจมีข้อจำกัดในกรณีที่ข้อมูลมี class imbalance เนื่องจากพิกเซลของคลาสใหญ่จะมีอิทธิพลต่อค่าความสูญเสียมากกว่า [5]

2.5.3 การใช้งานร่วมกันของ Dice Loss และ Cross-Entropy Loss

ในงาน segmentation หลายงานนิยมใช้ Dice Loss และ Cross-Entropy Loss ร่วมกัน เพื่อรวมข้อดีของทั้งสองฟังก์ชัน โดย Cross-Entropy Loss ช่วยให้โมเดลเรียนรู้การจำแนกพิกเซลได้อย่างเสถียร ในขณะที่ Dice Loss ช่วยปรับปรุงความแม่นยำของขอบเขตวัตถุและลดผลกระทบจาก class imbalance [21]

สำหรับโครงงานนี้ การใช้ loss function ทั้งสองร่วมกันช่วยให้แบบจำลองสามารถให้ผลลัพธ์ที่มีความแม่นยำมากขึ้น โดยเฉพาะในกรณีที่รอยโรคมีขนาดเล็กหรือมีลักษณะไม่สม่ำเสมอ ซึ่งสอดคล้องกับลักษณะของข้อมูลภาพช่องปากที่ใช้ในการทดลอง

2.6 การประมวลผลข้อมูลขั้นต้น (Preprocessing)

Preprocessing เป็นขั้นตอนสำคัญในการเตรียมข้อมูลก่อนนำเข้าสู่แบบจำลอง โดยมีวัตถุประสงค์เพื่อปรับปรุงคุณภาพของข้อมูล ลดสัญญาณรบกวน (noise) และทำให้ข้อมูลมีรูปแบบที่เหมาะสมต่อการเรียนรู้ของโมเดล [5] ในงานประมวลผลภาพ Preprocessing มักประกอบด้วยขั้นตอน เช่น การปรับขนาดภาพ (resizing), การปรับค่าความเข้มของพิกเซล (normalization), และการปรับปรุงความคมชัดของภาพ

การทำ normalization เป็นขั้นตอนที่สำคัญ เนื่องจากช่วยให้ค่าพิกเซลอยู่ในช่วงที่เหมาะสม ซึ่งส่งผลให้การฝึกโมเดลมีความเสถียรและสามารถเรียนรู้ได้รวดเร็วขึ้น นอกจากนี้ การลด noise เช่น การใช้ Gaussian filtering หรือ median filtering ยังช่วยลดผลกระทบของข้อมูลรบกวนที่อาจทำให้โมเดลเรียนรู้ผิดพลาด

ในบริบทของงาน segmentation ทางการแพทย์ การทำ preprocessing มีบทบาทสำคัญในการช่วยให้โมเดลสามารถแยกแยะลักษณะของอวัยวะและรอยโรคได้ชัดเจนมากขึ้น โดยเฉพาะในกรณีที่ภาพมีความแปรปรวนสูง เช่น ความแตกต่างของแสง สี หรือคุณภาพของภาพ [11]

สำหรับโครงงานนี้ การทำ preprocessing ถูกนำมาใช้เพื่อปรับปรุงคุณภาพของภาพอินพุตก่อนการฝึกโมเดล ซึ่งช่วยให้แบบจำลองสามารถเรียนรู้คุณลักษณะของอวัยวะได้ดีขึ้น และลดความคลาดเคลื่อนในผลลัพธ์การแบ่งส่วนภาพเมื่อเปรียบเทียบกับการใช้โมเดลเพียงอย่างเดียว

2.7 การประมวลผลผลลัพธ์ (Post-processing)

Post-processing เป็นขั้นตอนที่ดำเนินการหลังจากแบบจำลองสร้างผลลัพธ์แล้ว โดยมีวัตถุประสงค์เพื่อปรับปรุงความถูกต้องและความสมบูรณ์ของผลลัพธ์การแบ่งส่วนภาพ [6] เทคนิคที่ใช้ในขั้นตอนนี้มักเป็นวิธีเชิงกฎ (rule-based methods) หรือการวิเคราะห์โครงสร้างของภาพ

วิธีการที่นิยมใช้ใน post-processing ได้แก่ การตรวจสอบการเชื่อมต่อของพิกเซล (connectivity analysis), การลบจุดรบกวนขนาดเล็ก (small object removal), การเติมช่องว่าง (hole filling) และการปรับขอบเขตของวัตถุให้เรียบขึ้น (boundary smoothing) โดยอาจใช้เทคนิคทางสัณฐานวิทยา (morphological operations) เช่น dilation และ erosion เพื่อปรับปรุงรูปร่างของวัตถุ [20]

ในงาน segmentation ทางการแพทย์ post-processing มีบทบาทสำคัญในการแก้ไขข้อผิดพลาดที่เกิดจากโมเดล เช่น การทำนายผิดในบางบริเวณ หรือการเกิด noise ใน segmentation mask ซึ่งอาจส่งผลต่อการวิเคราะห์ในขั้นตอนถัดไป [11]

โครงงานนี้ post-processing ถูกนำมาใช้เพื่อปรับปรุงผลลัพธ์ที่ได้จากโมเดล โดยเฉพาะในกรณีที่มีการทำนายผิดพลาดเป็นจุดเล็ก ๆ หรือมีความไม่ต่อเนื่องของบริเวณอวัยวะ ซึ่งช่วยให้ผลลัพธ์มีความสอดคล้องกับลักษณะทางกายวิภาคมากยิ่งขึ้น และเมื่อใช้ร่วมกับ preprocessing พบว่าสามารถเพิ่มประสิทธิภาพของระบบได้อย่างชัดเจน

2.8 Connectivity (การเชื่อมต่อของพิกเซล)

Connectivity เป็นแนวคิดพื้นฐานในงานประมวลผลภาพดิจิทัลที่ใช้ในการกำหนดความสัมพันธ์ระหว่างพิกเซลในภาพ เพื่อระบุว่าพิกเซลใดอยู่ในกลุ่มหรือวัตถุเดียวกัน โดยอาศัยการพิจารณาพิกเซลข้างเคียง (neighboring pixels) ซึ่งมีบทบาทสำคัญในกระบวนการวิเคราะห์โครงสร้างของภาพ เช่น การแยกวัตถุ (object extraction) และการระบุขอบเขตของบริเวณ [6, 20]

โดยทั่วไป Connectivity สามารถแบ่งออกได้เป็น 2 รูปแบบหลัก ได้แก่ 4-connectivity และ 8-connectivity ในกรณีของ 4-connectivity จะพิจารณาเฉพาะพิกเซลที่อยู่ด้านบน ล่าง ซ้าย และขวา ของพิกเซลเป้าหมาย ขณะที่ 8-connectivity จะรวมพิกเซลในแนวทแยง (diagonal) เข้าไปด้วย ทำให้สามารถตรวจจับการเชื่อมต่อของวัตถุได้ครอบคลุมมากยิ่งขึ้น

แนวคิดของ Connectivity ถูกนำไปใช้ในกระบวนการ connected component labeling ซึ่งเป็นเทคนิคที่ใช้ในการระบุและแยกวัตถุแต่ละชิ้นในภาพ โดยจะทำการจัดกลุ่มพิกเซลที่มีการเชื่อมต่อกันให้อยู่ใน component เดียวกัน เทคนิคนี้มีความสำคัญในการวิเคราะห์ภาพ เช่น การนับจำนวนวัตถุ การวัดขนาด และการกรองวัตถุที่ไม่ต้องการ [19]

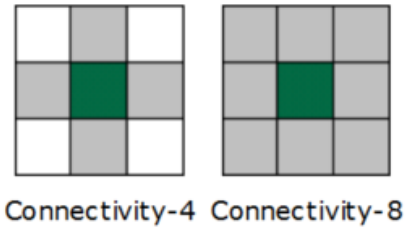

รูปที่ 2.7: ภาพแสดงความแตกต่างระหว่าง 4-connectivity และ 8-connectivity ในการพิจารณาการเชื่อมต่อของพิกเซล [15]

ในขั้นตอน preprocessing Connectivity สามารถนำมาใช้ในการวิเคราะห์โครงสร้างของวัตถุเบื้องต้น เช่น การตรวจสอบความต่อเนื่องของบริเวณที่สนใจ หรือการลบสัญญาณรบกวนที่ไม่เป็นส่วนหนึ่งของวัตถุหลัก ซึ่งช่วยให้ข้อมูลที่นำเข้าสู่โมเดลมีคุณภาพมากขึ้น

ในขณะเดียวกัน ในขั้นตอน post-processing Connectivity มีบทบาทสำคัญในการปรับปรุงผลลัพธ์ของการแบ่งส่วนภาพ โดยสามารถใช้ในการลบวัตถุขนาดเล็กที่ไม่เกี่ยวข้อง (small connected components removal) การรวมบริเวณที่ควรเป็นวัตถุเดียวกัน และการเติมช่องว่างภายในวัตถุ (hole filling) เพื่อให้ segmentation mask มีความสมบูรณ์และสอดคล้องกับลักษณะจริงของวัตถุมากยิ่งขึ้น

สำหรับโครงงานนี้ แนวคิดของ 8-connectivity ถูกนำมาใช้ในการวิเคราะห์วัตถุในภาพทั้งในขั้นตอน pre-processing และ post-processing เนื่องจากสามารถตรวจจับการเชื่อมต่อของพิกเซลได้ครอบคลุมมากกว่า 4-connectivity โดยเฉพาะในกรณีที่วัตถุมีลักษณะไม่เป็นระเบียบหรือมีขอบเขตที่ซับซ้อน ซึ่งช่วยปรับปรุงความถูกต้องของผลลัพธ์การแบ่งส่วนภาพได้อย่างมีประสิทธิภาพ

2.9 Evaluation Metrics

การประเมินประสิทธิภาพของแบบจำลองการแบ่งส่วนภาพ (image segmentation) มีความสำคัญในการวัดความสอดคล้องระหว่างผลลัพธ์ที่โมเดลทำนาย (prediction) และข้อมูลจริง (ground truth) โดยตัวชี้วัดที่นิยมใช้ ได้แก่ Precision, Recall, F1-score, Intersection over Union (IoU) และ Boundary F1 score ซึ่งสามารถสะท้อนประสิทธิภาพของโมเดลในมิติต่าง ๆ ได้อย่างครอบคลุม [16, 4]

2.9.1 Precision

Precision เป็นตัวชี้วัดที่ใช้วัดความถูกต้องของผลลัพธ์ที่โมเดลทำนายว่าเป็นวัตถุ โดยพิจารณาว่าพิกเซลที่ถูกทำนายว่าเป็นวัตถุ (positive) นั้นถูกต้องมากน้อยเพียงใด โดยคำนวณได้จากสูตร

$$\text{Precision} = \frac{TP}{TP + FP} \tag{2.3}$$

โดยที่ TP (True Positives) คือจำนวนพิกเซลที่ทำนายถูกต้อง, FP (False Positives) คือจำนวนพิกเซลที่ทำนายผิดว่าเป็นวัตถุ

Precision มีความสำคัญในกรณีที่ต้องการให้โมเดลมีความแม่นยำสูงในการทำนายวัตถุ โดยเฉพาะในงานที่การทำนายผิดอาจมีผลกระทบต่อการวิเคราะห์หรือการตัดสินใจ เช่น ในงานทางการแพทย์ที่การทำนายผิดอาจนำไปสู่การวินิจฉัยที่ไม่ถูกต้อง

2.9.2 Recall

Recall ใช้วัดความสามารถของโมเดลในการตรวจจับวัตถุทั้งหมด โดยพิจารณาว่าพิกเซลของวัตถุจริงถูกตรวจจับได้ครบถ้วนเพียงใด โดยคำนวณได้จากสูตร

$$\text{Recall} = \frac{TP}{TP + FN} \tag{2.4}$$

โดยที่ FN (False Negatives) คือจำนวนพิกเซลของวัตถุที่โมเดลไม่สามารถตรวจจับได้

Recall มีความสำคัญในกรณีที่ต้องการให้โมเดลสามารถตรวจจับวัตถุได้ครบถ้วน โดยเฉพาะในงานทางการแพทย์ที่การพลาดตรวจจับวัตถุอาจมีผลกระทบต่อการวินิจฉัยและการรักษา

2.9.3 F1-score

F1-score เป็นค่าเฉลี่ยแบบ harmonic mean ระหว่าง Precision และ Recall ซึ่งช่วยสร้างสมดุลระหว่างความแม่นยำและความครอบคลุมของโมเดล โดยคำนวณได้จากสูตร

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{2.5}$$

F1-score เหมาะสำหรับกรณีที่ข้อมูลมีความไม่สมดุล (class imbalance) ซึ่งมักพบในงาน segmentation ทางการแพทย์ [16]

2.9.4 Intersection over Union (IoU)

Intersection over Union (IoU) หรือ Jaccard Index เป็นตัวชี้วัดที่ใช้วัดความซ้อนทับระหว่างพื้นที่ที่โมเดลทำนายและข้อมูลจริง โดยพิจารณาสัดส่วนของพื้นที่ที่ซ้อนทับกันต่อพื้นที่รวมของทั้งสอง โดยคำนวณได้จากสูตร

$$\text{IoU} = \frac{TP}{TP + FP + FN} \tag{2.6}$$

IoU เป็นตัวชี้วัดที่นิยมใช้ในงาน segmentation เนื่องจากสามารถสะท้อนความแม่นยำของการแบ่งส่วนภาพได้อย่างชัดเจน โดยเฉพาะในกรณีที่ต้องการประเมินความสอดคล้องของขอบเขตวัตถุกับข้อมูลจริง [4]

2.9.5 Boundary F1 Score

Boundary F1 Score เป็นตัวชี้วัดที่ใช้ประเมินความถูกต้องของขอบเขต (boundary) ของวัตถุ โดยมุ่งเน้นไปที่ความสอดคล้องของเส้นขอบระหว่าง prediction และ ground truth ซึ่งมีความสำคัญในงาน segmentation ที่ต้องการความละเอียดสูง เช่น ภาพทางการแพทย์ [3]

แนวคิดของ Boundary F1 คือการพิจารณา Precision และ Recall เฉพาะบริเวณขอบของวัตถุ โดยใช้ระยะ tolerance ในการกำหนดว่าขอบที่ทำนายใกล้เคียงกับขอบจริงมากเพียงใด ซึ่งช่วยให้สามารถประเมินคุณภาพของ segmentation ในบริเวณที่มีความสำคัญสูงได้ดียิ่งขึ้น

ในโครงงานนี้ได้เลือกใช้ตัวชี้วัดหลายประเภทเพื่อให้สามารถประเมินประสิทธิภาพของโมเดลได้อย่างครอบคลุม โดย Precision, Recall และ F1-score ใช้ในการประเมินความถูกต้องของการจำแนกพิกเซล ขณะที่ IoU ใช้ในการวัดความสอดคล้องเชิงพื้นที่ และ Boundary F1 ใช้ในการประเมินความแม่นยำของขอบเขตของอวัยวะ

การใช้ตัวชี้วัดหลายรูปแบบร่วมกันช่วยให้สามารถวิเคราะห์จุดแข็งและข้อจำกัดของโมเดลได้อย่างละเอียด โดยเฉพาะในกรณีที่ผลลัพธ์มีความคลาดเคลื่อนบริเวณขอบวัตถุ หรือมีปัญหา class imbalance ซึ่งสอดคล้องกับลักษณะของข้อมูลภาพช่องปากที่ใช้ในการทดลอง

บทที่ 3
โครงสร้างและขั้นตอนการทำงาน

ในบทนี้จะกล่าวถึงหลักการ และการออกแบบระบบ

3.1 การจัดการข้อมูลและการเตรียมข้อมูล

ผู้จัดทำได้รับชุดข้อมูลภาพถ่ายช่องปาก มาจากศูนย์ทันตสาธารณสุขระหว่างประเทศ กรมอนามัย กระทรวงสาธารณสุข ซึ่งเป็นภาคีเครือข่ายวิจัยเดียวกันกับผู้จัดทำ ทั้งนี้ทันตแพทย์ ทันตบุคลากร และเจ้าหน้าที่ของกระทรวงสาธารณสุขภายใต้หน่วยงานดังกล่าวจะเป็นผู้เก็บรวบรวมข้อมูล และมีภารกิจในการลงพื้นที่ตาม ชุมชนต่าง ๆ เพื่อตรวจคัดกรองหารอยโรคก่อนมะเร็งและรอยโรคมะเร็งช่องปาก ทางผู้จัดทำได้คัดเลือกภาพ ที่ไม่ซ้ำกันมาจากชุดข้อมูลดังกล่าวเป็นจำนวน 1,692 ภาพ โดยแบ่งเป็นภาพที่มีรอยโรคก่อนมะเร็งและรอยโรคมะเร็งช่องปาก 1,259 ภาพ และภาพที่ไม่มีรอยโรค 433 ภาพ และแบ่งออกเป็น 9 มุมมองมาตรฐาน ได้แก่ มุมมองกระพุ้งแก้ม (Buccal mucosa view), มุมมองด้านหลังลิ้นและด้านข้างลิ้น (Dorsal and lateral tongue view), มุมมองพื้นปาก (Floor of mouth view), มุมมองเหงือก (Gingiva view), มุมมองเพดานปาก (Hard and Soft palate views), มุมมองริมฝีปาก (Lips view), มุมมองเหงือกด้านหลังฟันกรามล่าง (Retromolar pad view) และมุมมองลิ้นด้านล่าง (Ventral tongue view) โดยมีจำนวนภาพแบ่งตามมุมมองมาตรฐานและประเภทของรอยโรคดังแสดงในตารางที่ 3.1

ตารางที่ 3.1: ตารางแสดงจำนวนภาพแบ่งตามมุมมองมาตรฐานและประเภทของรอยโรค

มุมมองมาตรฐาน (Standard View)	**ภาพไม่มีรอยโรค**	**ภาพที่มีรอยโรค**
มุมมองกระพุ้งแก้ม (Buccal mucosa view)	242	149
มุมมองด้านหลังลิ้นและด้านข้างลิ้น (Dorsal and lateral tongue view)	195	73
มุมมองพื้นปาก (Floor of mouth view)	79	43
มุมมองเหงือก (Gingiva view)	150	80
มุมมองเพดานปาก (Hard and Soft palate views)	78	18
มุมมองริมฝีปาก (Lips view)	243	23
มุมมองเหงือกด้านหลังฟันกรามล่าง (Retromolar pad view)	158	34
มุมมองลิ้นด้านล่าง (Ventral tongue view)	114	13
รวมทั้งหมด	**1259**	**433**

จากนั้นทำการสร้างผลเฉลย (Ground truth) ด้วยเว็บแอปพลิเคชัน Labelbox [9] โดยให้ทันตแพทย์ผู้เชี่ยวชาญเป็นผู้ทำการวินิจฉัยและระบุขอบเขตของรอยโรคในภาพถ่ายช่องปากแต่ละภาพ โดยใช้เครื่องมือที่เหมาะสมในการวาดเส้นรอบรอยโรค และบันทึกข้อมูลดังกล่าวในรูปแบบที่สามารถนำไปใช้ในการฝึกสอนแบบจำลองการเรียนรู้เชิงลึกได้ แบ่งออกเป็น 9 คลาส ได้แก่ กระพุ้งแก้ม (Buccal mucosa), ด้านหลังลิ้นและด้านข้างลิ้น (Dorsal and lateral tongue), พื้นปาก (Floor of mouth), เหงือก (Gingiva), เพดานปาก (Hard and Soft palate), ริมฝีปาก (Lips), เหงือกด้านหลังฟันกรามล่าง (Retromolar pad) และลิ้นด้านล่าง (Ventral tongue)

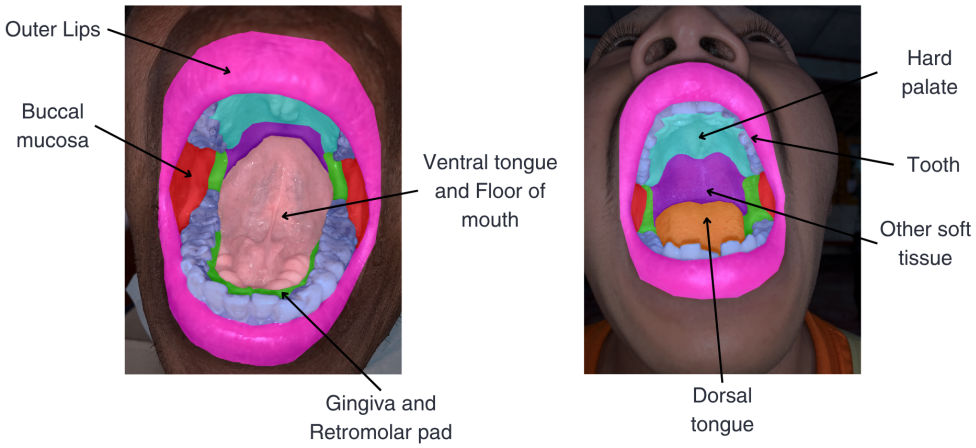

รูปที่ 3.1: ตัวอย่างภาพถ่ายช่องปากพร้อมผลเฉลย Ground truth ที่แสดงขอบเขตรอยโรค

3.2 การประมวลผลข้อมูลขั้นต้น (Preprocessing)

ในขั้นตอนการเตรียมข้อมูล มีวัตถุประสงค์เพื่อปรับปรุงคุณภาพของข้อมูลก่อนนำเข้าสู่แบบจำลอง โดยเน้นการลดสัญญาณรบกวน และปรับโครงสร้างของวัตถุให้มีความสอดคล้องกับลักษณะทางกายวิภาค ซึ่งประกอบด้วยขั้นตอนดังต่อไปนี้

3.2.1 การวิเคราะห์การกระจายขนาดวัตถุ (Object Size Distribution Analysis)

ในขั้นตอนแรก ได้ดำเนินการวิเคราะห์การเชื่อมต่อของพิกเซล (connectivity analysis) โดยใช้เทคนิค connected component labeling เพื่อแยกวัตถุแต่ละชิ้นใน Ground truth ออกจากกัน จากนั้นทำการคำนวณขนาดของแต่ละวัตถุ และวิเคราะห์การกระจายตัวของขนาดวัตถุ (object size distribution) ผลลัพธ์จากขั้นตอนนี้ถูกนำมาใช้ในการกำหนดเกณฑ์สำหรับการจำแนกวัตถุขนาดเล็กและวัตถุหลัก ซึ่งมีความสำคัญต่อขั้นตอนการปรับปรุงข้อมูลในลำดับถัดไป

3.2.2 การรวมวัตถุขนาดเล็ก (Context-aware Small Object Merging)

ในขั้นตอนนี้ ได้ดำเนินการปรับปรุงวัตถุขนาดเล็กโดยใช้การวิเคราะห์การเชื่อมต่อร่วมกับบริบทของวัตถุโดยรอบ (context-aware merging) โดยพิจารณาทั้งขนาดของวัตถุและความสัมพันธ์กับวัตถุข้างเคียง เริ่มต้นจากการระบุ connected components ของแต่ละคลาส (ยกเว้น background) จากนั้นคำนวณสัดส่วนของขนาดวัตถุเทียบกับพื้นที่ของอวัยวะทั้งหมด เพื่อจำแนกว่าวัตถุใดจัดเป็นวัตถุขนาดเล็ก

$$\text{Ratio} = \frac{\text{Area}_{comp}}{\sum P_{anatomy}} \times 100 \tag{3.1}$$

โดยที่ Area_{comp} คือจำนวนพิกเซลของวัตถุที่พิจารณา และ $\sum P_{anatomy}$ คือจำนวนพิกเซลรวมของทุกวัตถุที่ผ่านการทำ Labeling (คลาสที่ไม่ใช่ background) ในภาพนั้น ๆ

สำหรับวัตถุขนาดเล็ก จะทำการวิเคราะห์วัตถุข้างเคียงโดยใช้การขยายขอบเขต (dilation) เพื่อหาบริ-

เวณที่สัมผัสกัน (contact area) ระหว่างวัตถุ จากนั้นเลือกวัตถุเป้าหมายสำหรับการรวม โดยพิจารณาจากจำนวนพิกเซลที่สัมผัสกันมากที่สุด และในกรณีที่มีค่าการสัมผัสเท่ากัน จะใช้ขนาดของวัตถุเป็นตัวตัดสิน ในกรณีที่วัตถุขนาดเล็กไม่มีวัตถุข้างเคียงที่เหมาะสม จะถูกแปลงเป็น background เพื่อลดสัญญาณรบกวนในข้อมูล

นอกจากนี้ ยังมีการกำหนดเงื่อนไขเฉพาะสำหรับบางคลาส ได้แก่ การยกเว้นการรวมบริเวณสำหรับคลาสฟัน (Tooth) และริมฝีปาก (Lips) ที่มีขนาดเกินกว่าเกณฑ์สัญญาณรบกวนขั้นต่ำ เพื่อรักษาความถูกต้องเชิงกายวิภาคของข้อมูล

3.2.3 การรวมพื้นหลังภายในวัตถุ (Background Hole Merging)

ในขั้นตอนนี้ ได้ดำเนินการตรวจสอบบริเวณพื้นหลัง (background) ที่อยู่ภายในวัตถุ โดยใช้การวิเคราะห์ connected components เพื่อระบุบริเวณที่เป็นช่องว่างภายใน (holes)

สำหรับ background components ที่ถูกล้อมรอบด้วยวัตถุคลาสอื่นทั้งหมด และไม่ได้สัมผัสกับขอบของภาพ จะทำการวิเคราะห์คลาสของวัตถุรอบข้าง และเลือกคลาสที่มีจำนวนพิกเซลรอบข้างมากที่สุดเป็นคลาสเป้าหมาย จากนั้นทำการรวม background component เข้ากับคลาสดังกล่าว

กระบวนการนี้ช่วยแก้ไขปัญหาช่องว่างภายในวัตถุ และทำให้โครงสร้างของอวัยวะมีความต่อเนื่องมากขึ้น

3.2.4 การเติมเต็มช่องว่างภายในวัตถุ (Hole Filling)

ในขั้นตอนสุดท้าย ได้ดำเนินการเติมเต็มช่องว่างหรือรูพรุนขนาดเล็กที่ยังคงหลงเหลืออยู่ภายในวัตถุ โดยใช้เทคนิคทางสัณฐานวิทยา (morphological operations) กระบวนการนี้ช่วยให้โครงสร้างของวัตถุมีความสมบูรณ์ ลดความไม่ต่อเนื่องของพิกเซล และทำให้ Ground truth มีความเหมาะสมสำหรับการฝึกแบบจำลองมากยิ่งขึ้น

3.3 การปรับปรุงผลลัพธ์ (Post-processing)

หลังจากที่แบบจำลองทำการทำนายผลลัพธ์การแบ่งส่วนภาพแล้ว ได้มีการดำเนินการ post-processing เพื่อปรับปรุงความถูกต้องของผลลัพธ์ โดยเน้นการแก้ไขข้อผิดพลาดที่เกิดขึ้นจากการทำนายของโมเดล และปรับโครงสร้างของ segmentation mask ให้มีความสอดคล้องกับลักษณะทางกายวิภาคมากยิ่งขึ้น ซึ่งประกอบด้วยขั้นตอนดังต่อไปนี้

3.3.1 การลบวัตถุขนาดเล็กและการเติมเต็มช่องว่าง (Small Object Removal and Hole Filling)

ในขั้นตอนนี้ได้ดำเนินการปรับปรุงผลลัพธ์เบื้องต้นโดยใช้แนวคิดเดียวกับ preprocessing ได้แก่ การลบ connected components ที่มีขนาดเล็กเกินไป ซึ่งมักเกิดจากการทำนายผิดพลาดของโมเดล (false positives) และการเติมเต็มช่องว่างภายในวัตถุ (hole filling) เพื่อให้โครงสร้างของ segmentation mask มีความสมบูรณ์มากยิ่งขึ้น กระบวนการนี้ช่วยลดสัญญาณรบกวนและปรับปรุงความต่อเนื่องของวัตถุในภาพ

3.3.2 การวิเคราะห์ความสัมพันธ์ระหว่างคลาส (Class Containment Analysis)

จากการสังเกตผลลัพธ์ของแบบจำลองด้วยสายตา พบว่ามีข้อผิดพลาดในลักษณะที่คลาสหนึ่งครอบทับหรืออยู่ภายในอีกคลาสหนึ่ง (class containment) ในหลายกรณี ซึ่งส่งผลให้โครงสร้างของอวัยวะไม่สอดคล้องกับ

ความเป็นจริง

ดังนั้น จึงได้พัฒนาเครื่องมือในการวิเคราะห์ความสัมพันธ์ระหว่างคลาส โดยใช้การวิเคราะห์การเชื่อมต่อของพิกเซล (connectivity analysis) ร่วมกับเทคนิค connected component labeling เพื่อระบุว่ามีวัตถุของคลาสใดที่ถูกล้อมรอบหรือครอบทับโดยวัตถุของอีกคลาสหนึ่ง การวิเคราะห์ดังกล่าวช่วยให้สามารถระบุรูปแบบของข้อผิดพลาดที่เกิดขึ้นบ่อยในผลลัพธ์ของโมเดลได้อย่างเป็นระบบ

3.3.3 การปรับปรุงผลลัพธ์ด้วยกฎเชิงตรรกะ (Rule-based Correction)

จากผลการวิเคราะห์ความสัมพันธ์ระหว่างคลาส ได้นำข้อมูลที่ได้มาใช้ในการออกแบบกฎ (rule-based) สำหรับการปรับปรุงผลลัพธ์ โดยกำหนดเงื่อนไขในการแก้ไข label ของพิกเซลในบริเวณที่เกิด class containment กฎดังกล่าวถูกออกแบบโดยอิงจากรูปแบบข้อผิดพลาดที่พบจริงในผลลัพธ์ของโมเดล เช่น การกำหนดว่าหากคลาสหนึ่งปรากฏอยู่ภายในอีกคลาสหนึ่งในลักษณะที่ไม่สอดคล้องกับโครงสร้างทางกายวิภาค จะทำการปรับ label ให้เหมาะสม กระบวนการนี้ช่วยแก้ไขข้อผิดพลาดเชิงโครงสร้างที่โมเดลไม่สามารถเรียนรู้ได้โดยตรง และเพิ่มความสอดคล้องของผลลัพธ์กับลักษณะจริงของข้อมูล

บทที่ 4
การทดลองและผลลัพธ์

ในบทนี้จะทดสอบเกี่ยวกับการทำงานในฟังก์ชันหลักๆ

บทที่ 5
บทสรุปและข้อเสนอแนะ

5.1 สรุปผล

นศ. ควรสรุปถึงข้อจำกัดของระบบในด้านต่างๆ ที่ระบบมีในเนื้อหาส่วนนี้ด้วย

5.2 ปัญหาที่พบและแนวทางการแก้ไข

ในการทำโครงงานนี้ พบว่าเกิดปัญหาหลักๆ ดังนี้

5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อ

ข้อเสนอแนะเพื่อพัฒนาโครงงานนี้ต่อไป มีดังนี้

บรรณานุกรม

[1] Abhishek Chaurasia and Eugenio Culurciello. Linknet: Exploiting encoder representations for efficient semantic segmentation. In *IEEE Visual Communications and Image Processing (VCIP)*, 2017.

[2] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In *European Conference on Computer Vision (ECCV)*, 2018.

[3] Bowen Cheng et al. Boundary iou: Improving object-centric image segmentation evaluation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[4] Mark Everingham et al. The pascal visual object classes challenge: A retrospective. *International Journal of Computer Vision*, 111(1):98–136, 2015.

[5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[6] Robert M. Haralick, Stanley R. Sternberg, and Xinhua Zhuang. *Image Analysis Using Mathematical Morphology*. 1985.

[7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[8] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.

[9] Labelbox. Labelbox: The AI data platform. Available: https://labelbox.com/, 2025.

[10] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.

[11] Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, et al. A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42:60–88, 2017.

[12] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3431–3440, 2015.

[13] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. V-net: Fully convolutional neural networks for volumetric medical image segmentation. In *2016 Fourth International Conference on 3D Vision (3DV)*, pages 565–571, 2016.

[14] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos. Image segmentation using deep learning: A survey. *IEEE transactions on pattern analysis and machine intelligence*, 44(7):3523–3542, 2021.

[15] National Instruments. Connectivity. Available: https://www.ni.com/docs/en-US/bundle/ni-vision/page/connectivity.html, 2023. Accessed: 2026-03-26.

[16] David M. W. Powers. Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2011.

[17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241, 2015.

[18] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4510–4520, 2018.

[19] Linda G. Shapiro and George C. Stockman. *Computer Vision*. Prentice Hall, 2001.

[20] Pierre Soille. *Morphological Image Analysis: Principles and Applications*. Springer, 2003.

[21] Carole H. Sudre, Wenqi Li, Tom Vercauteren, Sebastien Ourselin, and M. Jorge Cardoso. Generalised dice overlap as a deep learning loss function for highly unbalanced segmentations. *Deep Learning in Medical Image Analysis*, 2017.

[22] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the International Conference on Machine Learning (ICML)*, 2019.

[23] C. Worachotsueptrakun. A comparison of 3d convolution neural networks for brain stroke classification with ct scan images. *Procedia of Multidisciplinary Research*, 1(5):14, 2023.

[24] Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. Unified perceptual parsing for scene understanding. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.

ภาคผนวก

ภาคผนวก ก
The first appendix

Text for the first appendix goes here.

ก.1 Appendix section

Text for a sections in the first appendix goes here.

test ทดสอบฟอนต์ serif ภาษาไทย

test ทดสอบฟอนต์ sans serif ภาษาไทย

test ทดสอบฟอนต์ teletype ภาษาไทย

test ทดสอบฟอนต์ teletype ภาษาไทย

ตัวหนา serif ภาษาไทย sans serif ภาษาไทย teletype ภาษาไทย

ตัวเอียง serif ภาษาไทย sans serif ภาษาไทย teletype ภาษาไทย

ตัวหนาเอียง serif ภาษาไทย sans serif ภาษาไทย teletype ภาษาไทย

https://www.example.com/test_ทดสอบ_url

ภาคผนวก ข
คู่มือการใช้งานระบบ

Manual goes here.

ประวัติผู้เขียน

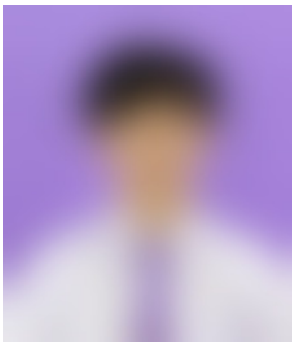

Your biosketch goes here. Make sure it sits inside the `biosketch` environment.